

Прогнозирование расходов МО и раннее обнаружение структурных сдвигов

Онлайн-конкурс СберИндекса 2026, направление «Прогнозирование». Панель: 13 140 рядов «территория x категория», 2 190 территорий, январь 2023 — декабрь 2024.

Отчёт собирается командой sbx report build из артефактов в artifacts/; все числа в тексте — результат последнего прогона, ручной правки чисел нет.

1. Задача и критерии

Требуется прогнозировать потребительские безналичные расходы муниципальных образований и как можно раньше выявлять структурные изменения. Обязательная метрика — MAE; отдельно оцениваются сравнение прогнозных моделей, сравнение методов обнаружения сдвигов, использование современных фундаментальных моделей, интеграция новостей, интерпретация и воспроизводимость.

2. Данные и идентификация МО

Панель: 303 126 наблюдений, 13 140 рядов «территория x категория», 2 190 территорий, январь 2023 — декабрь 2024.

Основной набор — архив организаторов конкурса: расходы на уровне МО с официальным кодом территории и справочник территорий. Панель построена по официальным кодам: 2 190 территорий, 13 140 рядов, 77 регионов; название, тип и ОКТМО взяты из редакции справочника 2024 года. 49 названий встречаются в нескольких регионах — это 121 территория, и различает их только код.

Для сверки те же наблюдения сопоставлены с публичной выгрузкой, где территория задана только названием. Идентификация по названиям относилась к чужому региону 327 из 13 140 рядов (2,5%): ряды из чужого региона попадали в 101 из 2 188 территорий, 14 территорий были отнесены к чужому региону целиком.

3. Протокол оценки

Rolling-origin бэкtest на четырёх горизонтах, которых требует критерий конкурса: 1, 3, 6 и 12 месяцев. Фолд (окно проверки) — это пара (горизонт, origin), а не origin с несколькими шагами: для direct-моделей горизонт меняет обучающую выборку. Всего 14 фолдов; чем длиннее горизонт, тем меньше origin-ов помещается в 24 месяца панели. Метрики считаются из единой OOF-таблицы; MAE — основная, R² приводится и pooled, и per-series.

Глобальные модели учатся на всех 13 140 рядах панели; сравниваются модели на 1 201 ряде замороженной оценочной выборки (configs/evaluation_series.csv).

Устойчиво ли различие двух моделей, решает счёт окон: знаковый тест показывает, держится ли знак разности по окнам проверки. Тест Диболда-Мариано по рядам приводится рядом как справочный: он считает ряды независимыми и завышает уверенность.

4. Сравнение прогнозных моделей

Модель	MAE, руб.	MAE macro, руб.	WAPE	R ² pooled	R ² per-series (медиана)	MASE
LightGBM	588.9	600.6	0.067	0.988	0.147	1.588
Ensemble	759.2	772.3	0.087	0.985	-0.256	2.181

Ensemble (по категориям)	779.8	790.8	0.09	0.984	-0.426	2.258
AutoTheta	843.9	855	0.097	0.98	-0.624	2.38
NHITS	860.2	873.5	0.098	0.978	-0.53	2.194
AutoETS	894.1	906.1	0.103	0.979	-0.658	2.463
Naive	913.4	925	0.105	0.977	-0.742	2.485
Chronos-2 (covariates)	923.3	939.3	0.106	0.978	-0.77	2.589
NBEATSx	927.9	940.2	0.106	0.976	-0.682	2.339
Chronos-2 (grouped)	953.3	966.8	0.11	0.975	-0.925	2.615
TimesFM-2.5	959.3	971	0.111	0.976	-0.905	2.666
Chronos-2	996	1009.5	0.115	0.974	-1.161	2.76
AutoARIMA	1140.8	1144.1	0.131	0.957	-1.033	3.083
SeasonalNaive	1306.4	1330.7	0.15	0.962	-1.81	3.589
Prophet	3142.9	3199.8	0.362	0.532	-23.513	7.956

Сводная таблица усредняет все горизонты, на которых модель определена. LightGBM, NHITS, NBEATSx при $h=12$ неопределимы, поэтому этот горизонт в их среднее не входит, и сравнивать их с остальными моделями по этой таблице нельзя. Лучшая модель выбирается внутри горизонта: 1 месяц — Chronos-2 (covariates) (581,7 руб.); 3 месяца — Chronos-2 (covariates) (588,6 руб.); 6 месяцев — LightGBM (422,0 руб.); 12 месяцев — Ensemble (793,7 руб.).

MAE по горизонтам прогноза

Критерий конкурса требует четырёх горизонтов: 1, 3, 6 и 12 месяцев. Каждый горизонт — самостоятельный набор фолдов, а не срез одного прогона: для direct-моделей горизонт меняет обучающую выборку.

Модель	mae h=1	mae h=3	mae h=6	mae h=12
Chronos-2 (covariates)	581.7	588.6	640.8	1136.5
AutoTheta	640.6	677.6	651.8	963.2
Chronos-2 (grouped)	642.6	721.3	790	1104.1
Chronos-2	648.4	738.6	848.5	1157.6
Ensemble (по категориям)	656.4	687.2	483.7	881.6
TimesFM-2.5	661.5	729	786.7	1109.7
LightGBM	678.6	642.5	422	—
Prophet	683.3	835.9	1353.8	4596.5
AutoETS	717.5	752.7	743.3	993.8
NHITS	747	946.2	763.6	—
AutoARIMA	765.7	832.5	782.9	1362.0
Naive	788	810.7	759.8	993.3
Ensemble	811.1	783.3	485	793.7
NBEATSx	935.3	1005.8	767.1	—
SeasonalNaive	1272.5	1278	1296.6	1322.5

Сравнение опирается на разное число моделей: $h=1$: 15 моделей на 4 431 наблюдениях, $h=3$: 15 моделей на 13 287 наблюдениях, $h=6$: 15 моделей на 6 640 наблюдениях, $h=12$: 12 моделей на 36 758 наблюдениях.

Пропуск в ячейке означает «неопределимо», а не «плохо». Глобальный LightGBM при $h=12$ не обучается вовсе: direct-модели нужен обучающий origin не позже cutoff – 12 месяцев, а панель начинается в январе 2023 — таких origin нет. Нейросети при $h=12$ пропускают фолд по той же причине: после вычета горизонта и валидационного окна на вход не остаётся ни одного месяца.

Оговорка по $h=12$. Тестовое окно в 12 месяцев помещается только от origin не позже декабря 2023, поэтому фолда всего три и они перекрываются на 10–11 месяцев из 12, а обучение сокращается до 10–12 месяцев. Это не три независимых наблюдения, и разброс

между ними нельзя читать как оценку устойчивости.

Значимость различий

Лучшая модель горизонта против эталонов. Отрицательная ΔMAE означает, что она точнее.

Горизонт	Лучшая модель	Сравнение	ΔMAE , руб.	p по рядам	точнее эталона
h=1	Chronos-2 (covariates)	против Prophet	-97,5	2.14e-14	в 1 окне из 4
h=1	Chronos-2 (covariates)	против Naive	-210,3	1.83e-62	в 2 окнах из 4
h=1	Chronos-2 (covariates)	против SeasonalNaive	-687,1	8.95e-88	в 3 окнах из 4
h=3	Chronos-2 (covariates)	против Prophet	-246,6	1.62e-59	в 3 окнах из 4
h=3	Chronos-2 (covariates)	против Naive	-228,5	6.70e-61	в 3 окнах из 4
h=3	Chronos-2 (covariates)	против SeasonalNaive	-687,8	2.25e-83	в 4 окнах из 4
h=6	LightGBM	против Prophet	-933,0	8.85e-79	в 1 окне из 1
h=6	LightGBM	против Naive	-337,9	8.21e-89	в 1 окне из 1
h=6	LightGBM	против SeasonalNaive	-876,6	4.00e-75	в 1 окне из 1
h=12	Ensemble	против Prophet	-3 800,5	1.42e-86	в 3 окнах из 3
h=12	Ensemble	против Naive	-196,1	1.67e-59	в 3 окнах из 3
h=12	Ensemble	против SeasonalNaive	-540,4	2.74e-72	в 3 окнах из 3

Как читать. «p по рядам» — панельный тест Диболда-Мариано: в нём ряды считаются независимыми наблюдениями. Он отвечает на вопрос, различаются ли модели в этих окнах проверки, но не на вопрос, повторится ли различие в другом окне: все прогнозы окна строит одна обученная модель, а шоки месяца у рядов общие. Поэтому рядом стоит счёт окон. Окон мало — от одного до четырёх на горизонт, при 12 месяцах они перекрываются, — и по ним можно судить только о том, держится ли знак.

По окнам проверки лучшая модель точнее Prophet: 1 месяц — в 1 окне из 4; 3 месяца — в 3 окнах из 4; 6 месяцев — в 1 окне из 1; 12 месяцев — в 3 окнах из 3. На горизонте 1 месяц средний перевес создан меньшинством окон: в остальных точнее Prophet.

Лучшая модель зависит от горизонта: h=1 — Chronos-2 (covariates), h=3 — Chronos-2 (covariates), h=6 — LightGBM, h=12 — Ensemble.

Ранговое сравнение Фридмана и критические разности Немени по каждому горизонту — в [artifacts/metrics/significance.json](#).

5. Обнаружение структурных изменений

Детектор	тип	вход	параметр	precision	recall	f1	covering	задержка	ложных/ряд-год
periodic	baseline	none	6	0.142	0.572	0.227	0.422	2.182	1.287
window_l2	offline	raw	0.5	0.151	0.419	0.222	0.591	2.704	0.876
cusum	online	residual	3	0.149	0.43	0.221	0.647	2.275	0.889
page_hinkley	online	residual	3	0.139	0.529	0.22	0.558	2.695	1.215
page_hinkley	online	raw	5	0.148	0.421	0.219	0.601	3.242	0.9
pelt_l2	offline	raw	30	0.172	0.29	0.216	0.665	3.304	0.519
binseg_l2	offline	raw	30	0.17	0.279	0.211	0.664	3.365	0.507
conformal	online	raw	2	0.144	0.388	0.21	0.643	3.053	0.849
kernel_rbf	offline	raw	3	0.19	0.203	0.197	0.688	3.797	0.322
pelt_rbf	offline	raw	3	0.19	0.203	0.196	0.688	3.797	0.322
conformal	online	residual	1.5	0.145	0.275	0.19	0.659	3.55	0.599
cusum	online	raw	8	0.13	0.336	0.188	0.637	3.732	0.824

Эталон сравнения — тревога по расписанию, каждые 6 месяцев независимо от данных: F1 0,227. Выше эталона по F1 — 0 из 15 вариантов «метод × вход».

Лучший онлайн-детектор по остаткам прогноза — CUSUM: F1 0,221, задержка 2,3 мес. Лучший по

сырому ряду — Page-Hinkley: F1 0,219, задержка 3,2 мес. Тот же CUSUM по сырому ряду — F1 0,188.

Расписание с ближайшей частотой ложных тревог — раз в 8 месяцев (0,87 на ряд в год против 0,89 у детектора): оно находит 34% слов и срабатывает через 3,1 мес. после слома; CUSUM по остаткам прогноза — 43% и 2,3 мес. Разница в полноте — 8,6 п.п., 95%-й интервал бутстрепа по рядам — от 2,7 до 14,7 п.п.

На рядах без внесённого слома CUSUM поднимает тревогу у 71% рядов, на рядах со сломом — у 80%: разметка покрывает только внесённые сломы, а собственные изменения настоящих рядов в ней не отмечены.

На настоящих остатках ансамбля (1 111 рядов оценочной выборки, один прогноз на месяц) CUSUM поднимает 3 049 тревог — 2,75 на ряд в год; конформный детектор по интервалам ансамбля — 422. Хотя бы одна тревога — у 935 рядов из 1 111 (84%). Остатки смещены: факт выше прогноза в 70,4% месяцев, поэтому часть тревог отражает систематическое отставание прогноза, а не смену режима.

Полнота по типам слов, проверка на национальных рядах и разбор выбора детектора — [reports/changepoints.md](#).

6. Foundation-модели: что дают и чего не дают

Проверены две модели с разрешающими лицензиями на веса — Chronos-2 (Apache-2.0) и TimesFM 2.5 (Apache-2.0). Moirai и TimesFM 3.0 исключены: их веса под некоммерческой лицензией, см. [THIRD_PARTY_MODELS.md](#).

Модель	mae h=1	mae h=3	mae h=6	mae h=12	покрытие 0,1–0,9
Chronos-2 (covariates)	581.7	588.6	640.8	1136.5	0.728
AutoTheta	640.6	677.6	651.8	963.2	—
Chronos-2 (grouped)	642.6	721.3	790	1104.1	0.831
Chronos-2	648.4	738.6	848.5	1157.6	0.826
TimesFM-2.5	661.5	729	786.7	1109.7	0.641

Лучшая одиночная модель (без ансамблей): h=1 — Chronos-2 (covariates), h=3 — Chronos-2 (covariates), h=6 — LightGBM, h=12 — AutoTheta.

Главные выводы: выигрыш даёт не сама foundation-модель, а передача ей ковариат. Chronos-2 без ковариат точнее простого AutoTheta на 0 из 4 горизонтов, с ковариатами — на 3 из 4 и становится лучшей одиночной моделью при h=1, 3. TimesFM 2.5 zero-shot точнее AutoTheta на 0 из 4 горизонтов. Публичные лидерборды foundation-моделей не переносятся на конкретную задачу, и проверять нужно собственным бэктестом. Подробности — [reports/models.md](#).

7. Новости и внешние данные

Источник — архивные суточные файлы GDELT Events за 2022-10...2024-12, отфильтрованные по России на лету (3,01 млн событий, 90 МБ). Архив скачивает `make gdelt` и сверяет с `data/gdelt_manifest.yaml`; по неполному архиву признаки не строятся.

Признаки строятся на уровне «регион x месяц» и «страна x месяц». Дополнительно ведётся курируемый календарь событий с проверяемыми источниками.

Согласование по времени. Момент прогноза — конец последнего наблюдаемого месяца. В прогноз входит только то, что опубликовано к концу месяца, от которого делается прогноз: новости — по дате попадания события в базу (DATEADDED), события календаря — по дате публикации, национальные ряды — с лагом публикации своего источника, отсчитанным от конца отчётного периода. На всех шагах многоступенчатого прогноза стоят одни и те же значения, известные на момент прогноза; на целевой месяц берётся только производственный календарь, известный заранее. Лаги — `configs/features.yaml`, проверка — `tests/test_leakage.py`.

Источник	Что берётся	Уровень	Согласование по времени	Что дал
Национальные ряды СберИндекса:	61 макропризнак; сезонный индекс	страна	лаг публикации 7–60 дней от ко	к базовой модели: +25,7 руб., ..
Производственный календарь Рос.	рабочие дни, праздники, сокращ	страна	известен заранее: берётся на ц	к базовой модели: –61,9 руб., ..
Новости GDELT 1.0	46 признаков: число событий, т	регион, стра	по дате попадания события в ба	к базовой модели: –3,1 руб., л.
Календарь событий – составлен	решения Банка России по ставке	регион, стра	по дате публикации события	к базовой модели: +50,5 руб., ..
Индекс доступности рынков – на	логарифм индекса доступности р	МО	постоянная характеристика терр	к базовой модели: +7,3 руб., х.
Автомобильные связи между МО –	5 ближайших по автодороге МО п	МО	расходы соседей – по месяц про	к базовой модели: +37,6 руб., ..
Погода NASA POWER (реанализ ME	отклонение температуры и осадк	МО	лаг публикации 7 дней: к концу	к базовой модели: –9,4 руб., л.
Росстат: численность населения	логарифм численности населения	МО	постоянная характеристика: оце	к базовой модели: +5,3 руб., х.

Измеренный вклад слоёв (раздел 9; вывод — по окнам проверки):

- Календарь и национальные ряды: устойчивого изменения нет — MAE ниже на 37,8 руб. в среднем, лучше в 7 окнах из 10.
- Новости и календарь событий поверх них: устойчивого изменения нет — MAE выше на 22,9 руб. в среднем, хуже в 5 окнах из 10.
- Foundation-модели в ансамбле: устойчивого изменения нет — MAE выше на 3,1 руб. в среднем, хуже в 7 окнах из 10.
- Все слои вместе против базовой модели: устойчивого изменения нет — MAE ниже на 11,3 руб. в среднем, лучше в 4 окнах из 10.

8. Модель вероятности шока на 1-3 месяца вперёд

PR-AUC (h=3): 0,128 при базовой доле 0,092.

Сравнение с онлайн-детектором при равном числе тревог:

Метрика	Модель шока	Онлайн-детектор
precision	0,092	0,145
recall	0,127	0,211
F1	0,107	0,172
задержка, мес.	3,68	2,59
ложных на ряд-год	0,460	0,447

Результат отрицательный: модель не входит в итоговую систему. При равном числе тревог она проигрывает простому детектору по остаткам (F1 0,107 против 0,172), и раннее предупреждение обеспечивает именно детектор. Разбор — [reports/changepoints.md](#).

9. Абляции: измеренный вклад каждого слоя

Конфигурация	MAE, руб.	ΔMAE к A	R ² per-series	F1 CPD	ложных на ряд-год	задержка, мес.
A	635.221	0	-0.243	0.222	0.876	2.704
B	596.691	-38.53	-0.142	0.222	0.876	2.704
C	618.848	-16.373	-0.205	0.222	0.876	2.704
D	600.421	-34.8	0.068	0.222	0.876	2.704
E	623.248	-11.973	-0.002	0.222	0.876	2.704
F	623.248	-11.973	-0.002	0.221	0.889	2.275

В столбцах обнаружения у конфигураций A–E стоит лучший офлайн-метод по сырому ряду, у F — онлайн-детектор по остаткам прогноза: слой F меняет способ обнаружения, а не прогноз.

Все конфигурации измерены на одних и тех же 31 238 наблюдениях. В таблице — разница общих MAE; в тесте значимости — средняя по рядам разность ошибок, поэтому эти числа немного расходятся.

Вклад каждого источника по отдельности

LightGBM с одним добавленным блоком признаков против того же варианта без него: к базовой модели (А) и поверх календаря и национальных рядов (В). Разность — средняя по рядам, отрицательная означает, что с источником ошибка меньше. «По окнам» — в скольких окнах проверки знак разности тот же, что в среднем: «лучше в 8 окнах из 10» при отрицательной разности, «хуже в 4 окнах из 10» при положительной. Вывод «устойчиво» ставится, только если знак держится по окнам (знаковый тест, уровень 0,05).

Источник	К чему добавлен	ΔMAE, руб.	по окнам	вывод	по горизонтам 1 / 3 / 6 мес.	р по рядам
Производственный календарь	к базовой модели	-61,9	лучше в 8 окнах из 10	неустойчиво	-4,6 / -47,5 / -95,5	р < 0,001
Национальные ряды СберИндекса	к базовой модели	+25,7	хуже в 6 окнах из 10	неустойчиво	-7,5 / +6,6 / +57,9	р < 0,001
Новости GDELT	к базовой модели	-3,1	лучше в 6 окнах из 10	неустойчиво	-5,9 / -71,9 / +67,7	р = 0,21
Новости GDELT	поверх календаря и национальных рядов	-2,6	лучше в 5 окнах из 10	неустойчиво	+28,0 / -21,5 / +5,5	р = 0,06
Календарь событий	к базовой модели	+50,5	хуже в 5 окнах из 10	неустойчиво	+4,9 / +70,7 / +44,6	р < 0,001
Календарь событий	поверх календаря и национальных рядов	+0,4	хуже в 5 окнах из 10	неустойчиво	+0,6 / +15,8 / -15,2	р = 0,80
Доступность рынков и расстояния	к базовой модели	+7,3	хуже в 6 окнах из 10	неустойчиво	-15,3 / +2,9 / +20,1	р < 0,001
Доступность рынков и расстояния	поверх календаря и национальных рядов	+26,3	хуже в 6 окнах из 10	неустойчиво	+26,1 / +58,3 / -5,9	р < 0,001
Расходы соседних МО по автодорогам	к базовой модели	+37,6	хуже в 7 окнах из 10	неустойчиво	+13,5 / +50,1 / +33,6	р < 0,001
Расходы соседних МО по автодорогам	поверх календаря и национальных рядов	+5,6	хуже в 6 окнах из 10	неустойчиво	+69,3 / +30,8 / -40,5	р = 0,001
Погода NASA POWER	к базовой модели	-9,4	лучше в 6 окнах из 10	неустойчиво	+10,0 / -44,8 / +18,0	р = 0,007
Погода NASA POWER	поверх календаря и национальных рядов	+11,3	хуже в 7 окнах из 10	неустойчиво	+15,7 / +32,5 / -11,8	р < 0,001
Численность населения МО (Росстат)	к базовой модели	+5,3	хуже в 6 окнах из 10	неустойчиво	-26,6 / -9,4 / +29,1	р = 0,01
Численность населения МО (Росстат)	поверх календаря и национальных рядов	+30,0	хуже в 6 окнах из 10	неустойчиво	+12,3 / +59,5 / +6,8	р < 0,001

Сравнение пар конфигураций (ΔMAE < 0 — левая точнее). Вывод ставится по окнам проверки: тест по рядам считает ряды независимыми и здесь завышает уверенность.

Пара	ΔMAE, руб.	по окнам	вывод	р по рядам
В против А	-37,8	лучше в 7 окнах из 10	неустойчиво	1.49e-31
С против В	+22,9	хуже в 5 окнах из 10	неустойчиво	1.51e-36
Д против В	+3,1	хуже в 7 окнах из 10	неустойчиво	6.48e-01
Е против А	-11,3	лучше в 4 окнах из 10	неустойчиво	1.28e-01

10. Разборы реальных примеров

- Всего: скользящее окно (L2) со штрафом, откалиброванным на бенчмарке, находит 3 из 5 размеченных шоков, всего 9 тревог; окна допуска вокруг них накрывают 47% ряда (reports/figures/case_national_всего.png).
- Услуги: скользящее окно (L2) со штрафом, откалиброванным на бенчмарке, находит 3 из 5 размеченных шоков, всего 12 тревог; окна допуска вокруг них накрывают 59% ряда (reports/figures/case_national_услуги.png).
- Мотыгинский муниципальный район (Красноярский край) · Маркетплейсы: крупнейший остаток прогноза ($|z| = 18,3$) — не шок, а быстрый структурный рост категории, за которым модель не успевает.

На национальных месячных рядах лучший офлайн-метод — скользящее окно (L2) (F1 0,270, recall 0,400).

Полные разборы с графиками — reports/cases.md.

11. Ограничения

Перечислены честно, включая те, что ослабляют выводы решения.

- История — 24 месяца на ряд. Годовая сезонность и тренд не идентифицируются: у каждого МО всего два декабрия. На горизонте 12 месяцев это становится жёстким ограничением: direct-модели неопределимы, а фолдов помещается лишь три, и те перекрываются на 10-11 месяцев из 12. В сводке по всем горизонтам R^2 по отдельным рядам отрицателен у 14 из 15 моделей.

- Утечка бенчмарков в предобучение foundation-моделей. Публичные лидерборды Chronos и TimesFM не переносятся на эту задачу, и проверить, не видели ли веса похожие данные, невозможно. Все выводы делаются только по собственному rolling-origin бэктесту.
- Аддитивность показателя не гарантирована. Значение задано в рублях с медианой около 25 тыс. в месяц, что похоже на средние расходы на клиента, а такие величины не суммируются. Поэтому согласование прогнозов по иерархии «МО → регион → РФ» (MinT) в решение не входит.
- Реальных размеченных шоков на уровне МО почти нет. Приграничных МО Курской области в датасете нет; паводок в Орске в месячном итоге не виден. Методы обнаружения сравниваются на полусинтетическом бенчмарке, а реальная проверка возможна только на национальных рядах.
- Вклад внешних данных — то, что показала абляция, а не то, что ожидалось. Календарь и национальные ряды: устойчивого изменения нет — MAE ниже на 37,8 руб. в среднем, лучше в 7 окнах из 10. Новости и календарь событий поверх них: устойчивого изменения нет — MAE выше на 22,9 руб. в среднем, хуже в 5 окнах из 10.
- Лицензионные исключения. Moirai, TimesFM 3.0, TiRex, TabPFN-TS и TimeGPT не использованы: некоммерческие лицензии весов или закрытый API. Это сузило выбор foundation-моделей до двух.
- Часть новостей без региона. 30,2% событий GDELT привязаны только к стране; они идут в отдельный блок признаков уровня страны.
- Оценка на подвыборке. Модели сравниваются на 1 201 ряду оценочной выборки: Prophet обучается отдельно на каждый ряд, и полная панель для него недостижима за время конкурса. Общих наблюдений всех моделей по горизонтам: 1 месяц — 4 431; 3 месяца — 13 287; 6 месяцев — 6 640; 12 месяцев — 36 758.
- Окон проверки мало: на 1 месяц — 4, на 3 месяца — 4, на 6 месяцев — 1, на 12 месяцев — 3. Различия моделей измерены в этих окнах; повторяются ли они в другом периоде, по таким данным сказать нельзя. По окнам проверки лучшая модель точнее Prophet: 1 месяц — в 1 окне из 4; 3 месяца — в 3 окнах из 4; 6 месяцев — в 1 окне из 1; 12 месяцев — в 3 окнах из 3. На горизонте 1 месяц средний перевес создан меньшинством окон: в остальных точнее Prophet.
- Основная модель выбрана по тем же окнам. Основной LightGBM получает производственный календарь на целевой месяц; гиперпараметры не подбираются. Эта конфигурация выбрана после сравнения вариантов модели на тех же окнах проверки, поэтому её оценка оптимистична: лучший из нескольких вариантов на новых данных обычно оказывается хуже, чем на тех, по которым его выбрали.
- Часть постоянных характеристик известна позже момента прогноза. Тип МО взят из редакции справочника 2024 года: у 84 территорий из 2 190 он отличается от редакции 2023 года, и для окон проверки от месяцев 2023 года это сведение из следующей редакции. Индекс доступности рынков и расстояния между МО рассчитаны организаторами по данным 2024 года — позже части моментов прогноза.
- Сравнение детекторов читается только рядом с расписанием. Тревога по расписанию, не глядя на данные, даёт F1 0,227; выше неё — 0 из 15 вариантов «метод × вход». F1 с окном допуска на этом бенчмарке не отличает метод от расписания; отличает сравнение при равной частоте ложных тревог.

12. Воспроизведение

uv sync --all-extras

```
make validate      # сверка файлов данных с манифестами
make gdelt         # архив новостей GDELT: скачать и сверить с манифестом
make entities      # таблица территорий по официальным кодам, сверка идентификации
make panel         # каноническая панель и сезонные индексы
make features      # календарь, национальные ряды, новости, события, соседние МО, погода, население
make backtest      # прогнозные модели, ансамбль, значимость по горизонтам
make cpd           # бенчмарк обнаружения сдвигов, национальная проверка, разборы
make ablations     # матрица абляций и вклад каждого источника
make report        # отчёт и лендинг
```

make all # всё перечисленное подряд, в этом порядке

То же в контейнере, без установки uv и Python: docker compose run --rm pipeline.
Сеть нужна при первом прогоне: make gdelt скачивает архив новостей, make backtest — веса foundation-моделей. Набор организаторов, таблица погоды и таблица численности населения лежат в репозитории; команды sbx data official, sbx data weather и sbx data population нужны, только чтобы получить их заново. Без архива новостей конфигурации абляций C, E, F и модель раздела 8 получаются другими; что делать, если источник недоступен, — в README.
Все гиперпараметры — в configs/*.yaml, все числа отчёта — из artifacts/.

13. Где закрыт каждый критерий

Критерий	Раздел отчёта	Артефакты
Понятность методологии	весь отчёт	—
Качество прогноза (MAE)	разделы 3, 4	artifacts/metrics/leaderboard.csv
Сравнение методов обнаружения	разделы 5 и 8, reports/changepoints.md	artifacts/cpd/detector_comparison.csv
Современные foundation-модели	раздел 6	artifacts/oof/chronos2.parquet, timesfm25.parquet
Интеграция новостей	раздел 7	artifacts/news/, configs/events.yaml
Интерпретация и выводы	разделы 9–11, reports/cases.md	artifacts/ablations/, artifacts/cases/
Воспроизводимость	раздел 12, README	data/manifest.yaml, configs/